



FUNDAMENTOS E TÉCNICAS EM CIÊNCIAS DE DADOS

PROF. JOSENALDE OLIVEIRA

josenalde.oliveira@ufrn.br

<https://github.com/josenalde/datascience>

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS - UFRN



Ensino: Fundamentos e Técnicas em Ciência de Dados (EAJ/TADS)
Aprendizado de Máquina (EAJ/TADS)
Programação Avançada: IA (EAJ/TECINFO)
Aprendizado Profundo (IMD/PPgTI)

Pesquisa: engenheiro de IA sênior (ASUS CORTEX@IMD)
analista de governança de dados pleno (CONAB@IFRN)
IA na OBR (tecinfo - visão computacional)
Automação baseada em LLM

OBJETIVOS

O(a) discente selecionará, com base na origem dos dados, as ferramentas e técnicas para pré-processamento (limpeza), tratamento e processamento de dados, com a respectiva saída gráfica ou textual para auxílio à tomada de decisão. Adquirirá uma visão ampla dos softwares, bibliotecas, métodos estatísticos e linguagens utilizadas na área de ciência de dados, de modo a incorporar tais soluções no desenvolvimento de software.

CONTEÚDO

Unidade I: introdução à ciência de dados, big data e suas etapas (produção; armazenamento (nosql); transformação e armazenamento analítico (olap, data warehouse, BI, data discovery), dashboards; **Unidade II:** processamento paralelo, distribuído e tempo real (hadoop, spark, spark streaming); **Unidade III:** análise de dados, métricas estatísticas e visualização, noções de mineração de dados e técnicas de predição (regressão linear simples, logística, séries temporais)

PLANO DE CURSO

DESCRIÇÃO, ARMAZENAMENTO

Introdução a ciência de dados e Big Data; Banco de dados não relacionais (desnormalização); Conceitos e definições sobre Ciência dos Dados; produção de dados; armazenamento; análise de dados; visualização, agrupamento e análise em rede. Caracterização, importância das etapas de modelagem e análise científica de dados. Ferramentas e linguagens para análise científica de dados.



PREDIÇÃO

Aquisição e formatação de dados. Análise estatística de dados. Agrupamento e classificação de dados. Visualização científica de dados. Principais conceitos para gerenciamento de Big Data; Tecnologias para Big Data; Técnicas estatísticas de predição; Data Discovery, OLAP e Visualização de Dados; Processamento paralelo e distribuído de dados; Visualização de dados: estática e interativa. Desenvolvimento de painéis de visualização (dashboards).

VISUALIZAÇÃO, ANÁLISE

Introdução a mineração de dados; Análise de dados de redes sociais. Modelagem de dados em grafos. Introdução a raspagem de dados (scraping). Coleta de dados estruturados e não estruturados. Desenvolvimento de raspadores de dados (scrapers). Ética e legislação sobre a raspagem de dados.

O que define um projeto de ciência de dados? A melhoria de algum aspecto no/do cliente

PLANO DE CURSO

- Referências

Notas de aula .pdf disponibilizadas de autoria do docente (slides)

IGUAL, Laura; SEGUÍ, Santi. Introduction to Data Science: a Python approach to concepts, techniques and applications. Springer, 2017.

<https://github.com/DataScienceUB/introduction-datascience-python-book>

E-book disponível em:

<https://www.springer.com/gp/book/9783319500164>

AMARAL, Fernando. Introdução à Ciência de Dados: mineração de dados e big data. Rio de Janeiro: Alta Books, 2016.



KELLEHER, John D.; TIERNEY, Brendan. Data Science. MIT Press, 2018.

* McKINSEY, Wes. Python para análise de dados. São Paulo: Novatec, 2018.

<https://github.com/wesm/pydata-book>

FERRAMENTAS (SUGERIDAS)

- Dentro da miríade (crescente) de ferramentas, é selecionado um ambiente interativo (Jupyter notebooks) baseado em **Python** para desenvolvimento de nossos estudos, a partir do qual bibliotecas e recursos extras vão sendo apresentados/explorados no tempo...



FERRAMENTAS (SUGERIDAS)

- Ganho de produtividade...

Pandas



```
import pandas as pd
acervobczm = pd.read_csv('../datasets/acervoquisicao.csv', sep=';')
```

Dataframe Pandas

- Provê estruturas de dados de alto nível para dados estruturados ou tabulares (Series, DataFrames)
- Início: 2010 (chave para o Python ganhar espaço em CD)
- Facilita reformatação, manipulação, agregação, seleção
- Tratamento flexível para dados ausentes

FERRAMENTAS (SUGERIDAS)

- Ganho de produtividade...

Dicionário Python

```
import csv

with open('../datasets/acervoquisicao.csv', encoding='utf8') as f:
    reader = csv.DictReader(f, delimiter=';')
    for row in reader:
        print(row['titulo'])
```

Dicionário

Chaves

Valores

"nome"

"Gandalf"

"classe"

"Wizard"

"ordem"

"Istari"

"altura"

"1.85"

```
dados = {
    "nome": "Gandalf",
    "classe": "Wizard",
    "ordem": "Istari",
    "altura": "1.85"
}
```

FERRAMENTAS (SUGERIDAS)

Dicionário	
Chaves	Valores
"nome"	"Gandalf"
"classe"	"Wizard"
"ordem"	"Istari"
"altura"	"1.85"

```
from pydantic import BaseModel
```

```
class Personagem(BaseModel):  
    nome: str  
    classe: str  
    ordem: str  
    altura: float
```

```
personagem = Personagem(  
    nome="Gandalf",  
    classe="Wizard",  
    ordem="Istari",  
    altura=1.85  
)
```

```
print(personagem)
```

Pydantic define/valida o **formato dos dados** em tempo de execução

```
dados = {  
    "nome": "Gandalf",  
    "classe": "Wizard",  
    "ordem": "Istari",  
    "altura": "1.85"  
}
```

```
personagem = Personagem(**dados)
```


EXEMPLO SIMPLES DE VALIDAÇÃO

```
def soma(a: int, b: int) -> int:  
    return a + b
```

```
print(soma(10,20)) #  
print(soma("10","20")) #
```

```
class Numeros(BaseModel):  
    a: int  
    b: int  
  
def soma(numeros: Numeros) -> int:  
    return numeros.a + numeros.b  
  
numeros = Numeros(a="10", b="20")  
print(soma(numeros))
```

FERRAMENTAS (SUGERIDAS)



- Provê objeto array multidimensional *ndarray* rápido e eficiente (alto desempenho) que as estruturas built-in
- Funções para processamento dos arrays
- Álgebra linear, Fourier, aleatórios etc.
- Escrita e leitura de blocos *ndarray* em disco
- API C para interoperabilidade C-python numPy



```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import pandas as pd
```

```
import seaborn as sns
```

```
import statsmodels as sm
```

FERRAMENTAS (SUGERIDAS)

- Qual linguagem base devo utilizar?

Ver esta análise [aqui](#)



Introduction	Methodology	Applications of PCA	Extensions of PCA	Final Remarks	References
○○○○○	○○○○○○○○○○○○○○	○○○○○○○●○○○○○○○○○○○○○○○○○○	○○○○○○○○○○○○○○		

Example 1: Food consumption in European Countries

Example 1: European Food Consumption

Step 3a: Perform PCA

R

```
out_cor <- princomp(data, cor=TRUE)

lambda_perc <- out_cor$sdev^2/sum(out_cor$sdev^2)
V <- out_cor$loadings
Y <- cor(data) %*% V # Y = XV
PC <- out_cor$scores # PC = (standardized dataset)V
### Compare with ?prcomp and ?svd
```


Python

```
data_std = data/data.std()

out_cor = PCA().fit(data_std)

lambda_perc = out_cor.explained_variance_ratio_
V = pd.DataFrame(out_cor.components_.T)
Y = pd.DataFrame(np.dot(data_corr(), V)) # Y = XV
PC = pd.DataFrame(out_cor.fit_transform(data_std))
### Compare with 'scipy.linalg',
### 'numpy.linalg' and
### 'matplotlib.mlab.PCA'
```

UPV



Ambas possuem suas especificidades, qualidades e, em geral, a escolha principal tem sido associada ao background do desenvolvedor, se em computação (python) ou de matemática/estatística (R)

OBS: python necessário para a análise de dados (codificação)

JUPYTER LAB (NOTEBOOK):



ANACONDA®

Anaconda Navigator

File Help

ANACONDA.NAVIGATOR

Home

Environments

Learning

Community

Applications on base (root) Channels

 CMD.exe Prompt 0.1.1 Run a cmd.exe terminal with your current environment from Navigator activated Launch	 Datalore Online Data Analysis Tool with smart coding assistance by JetBrains. Edit and run your Python notebooks in the cloud and share them with your team. Launch	 IBM Watson Studio Cloud IBM Watson Studio Cloud provides you the tools to analyze and visualize data, to cleanse and shape data, to create and train machine learning models. Prepare data and build models, using open source data science tools or visual modeling. Launch	 JupyterLab 2.2.6 An extensible environment for interactive and reproducible computing, based on the Jupyter Notebook and Architecture. Launch	 Notebook 6.1.4 Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis. Launch	 Powershell Prompt 0.0.1 Run a Powershell terminal with your current environment from Navigator activated Launch
 Qt Console 4.7.7 PyQt GUI that supports inline figures, proper multiline editing with syntax highlighting, graphical calltips, and more. Launch	 Spyder 4.1.5 Scientific Python Development Environment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features Launch	 VS Code 1.52.1 Streamlined code editor with support for development operations like debugging, task running and version control. Launch	 Glueviz 1.0.0 Multidimensional data visualization across files. Explore relationships within and among related datasets. Install	 Orange 3 3.26.0 Component based data mining framework. Data visualization and data analysis for novice and expert. Interactive workflows with a large toolbox. Install	 PyCharm Professional A full-fledged IDE by JetBrains for both Scientific and Web Python development. Supports HTML, JS, and SQL. Install
 RStudio 1.1.456 A set of integrated tools designed to help you be more productive with R. Includes R essentials and notebooks. Launch					

NUMFOCUS
OPEN CODE • BETTER SCIENCE
[Donate](#)

Support the OSS Community

Documentation

Anaconda Blog

JUPYTER LAB (NOTEBOOK):

The screenshot shows the Jupyter Lab interface. On the left is a file browser showing a directory structure with two notebooks: nb1.ipynb (modified 17 days ago) and nb2.ipynb (modified 9 minutes ago). The main area displays the nb2.ipynb notebook. It has a title bar with 'nb2.ipynb' and a toolbar with icons for saving, opening, and running. The notebook content includes a text cell with the instruction: '1) Leitura de arquivo .csv no disco local. Para este arquivo, não consegue ler sem o informar explicitamente o separador sep=';'' and a code cell with the following Python code:

```
[2]: import pandas as pd
acervobczm = pd.read_csv('../datasets/acervoaquisicao.csv', sep=';')
acervobczm.head()
#print(type(acervobczm))
```

Below the code cell, the output is displayed as a table:

	titulo	edicao	ano	autor	gestora_nome	quantidade	unidade_nome	ano_aquisicao	isbn	issn
0	PROMETHEUS - ATLAS DE ANATOMIA (3 VOLUMES)	0	2013	SCHUMACHER, UDO; SCHUNKE, MICHAEL; SCHULTE, ERIK	CENTRO DE CIÊNCIAS DA SAÚDE	80	COORDENAÇÃO DO CURSO DE MEDICINA	2020	9788527718264	NaN
1	RELIGIÃO NO POVO	0	2009	LUIS DA CAMARA CASCUDO	CENTRO DE CIÊNCIAS HUMANAS, LETRAS E ARTES	10	COORDENAÇÃO DO CURSO DE GEOGRAFIA A DISTÂNCIA ...	2020	8526010794	NaN
2	GESTÃO DE PROJETOS: AS MELHORES PRÁTICAS	0	2016	HAROLD KERZNER	CENTRO DE CIÊNCIAS HUMANAS, LETRAS E ARTES	3	COORDENAÇÃO DO CURSO DE GESTÃO DE POLÍTICAS PÚBLICAS	2020	9788582603802	NaN
3	MANUAL DE DIREITO ADMINISTRATIVO	5	2018	MATHEUS CARVALHO	CENTRO DE CIÊNCIAS HUMANAS, LETRAS E ARTES	4	COORDENAÇÃO DO CURSO DE GESTÃO DE POLÍTICAS PÚBLICAS	2020	9788544217528	NaN
4	TEORIAS DA COMUNICAÇÃO	0	2001	ANTONIO HOHLFELDT	CENTRO DE CIÊNCIAS HUMANAS, LETRAS E ARTES	1	COORDENAÇÃO DO CURSO DE JORNALISMO	2020	9788532626158	NaN

- Ambiente para execução interativa (Ipython), com mescla de código interpretável, texto, imagens, LaTeX – linguagem Markdown e HTML
- No Anaconda Prompt:
 - conda update jupyter
 - notebook jupyter

- Baseado no projeto Ipython (Fernando Pérez, 2001...)
- Projeto Jupyter (2014...)
- Desenvolvimento baseado no fluxo execução-exploração ao invés de edição-compilação-execução
- Em ciência de dados, as análises envolvem exploração, tentativa e erro e iteração

GOOGLE COLAB



O que é o Colaboratory?

O Colaboratory ou "Colab" permite escrever código Python no seu navegador, com:

- Nenhuma configuração necessária
- Acesso gratuito a GPUs
- Compartilhamento fácil

Você pode ser um **estudante**, um **cientista de dados** ou um **pesquisador de IA**, o Colab pode facilitar seu trabalho. Assista ao vídeo [Introdução ao Colab](#) para saber mais ou simplesmente comece a usá-lo abaixo!

- Desenvolvimento online com integração Gdrive e Github

Dito isto...

The Periodic Table of Data Science

[Data-Science-Periodic-Table.pdf](#)

An overview of key companies, resources and tools in data science (as of 4/12/2017)



Dc DataCamp	Ga General Assembly	Sd Strata Data
Sb SpringBoard	M Metis	Od ODSC
Ex Edx	Di Data Incubator	Tc Tableau Conference
C Coursera	In Insight	U UseR!
Uda Udacity	Dsa NYC Data Science Academy	Pd PyData
Ude Udemy	G Galvanize	Paw Predictive Analytics World
Ps Pluralsight	Dsg Data Science for Social Good	Kdd ACM SIGKDD Conference
Ly Lynda	Dsy Data Society	Tpc Teradata Partners Conference
Tt TeamTreeHouse	Dsj Data Science Dojo	Icd IEEE International Conference on Data Mining
Bdu Big Data University		

Courses

Boot camps

Conferences

Data

Projects & Challenges, Competitions

Programming Languages & Distributions

Search & Data Management

Machine Learning & Stats

Data Visualization & Reporting

Collaboration

Community & Q&A

News, Newsletters & Blogs

Podcasts


Py Python	Js JavaScript	Vb Visual Basic	Pgs PostgreSQL	Sli SQLite	Ah Apache Hadoop	W Weka	Bml BigML	Kn Knime	Sm Spark MLlib	Pb Power BI	Obi Oracle BI	Shn Shiny	Ddl Domino Data Lab	De Data Science Experience
R R	Cp C++	Sc Scala	Ar Amazon Redshift	Bq Google BigQuery	Hw Hortonworks	O Oracle	Dar DataRobot	Lib LibSVM	Ho H2O	Bo BusinessObjects	Alt Alteryx	Mpl Matplotlib	Nt Nteract	Rs Rstudio
S SQL	Pl Perl	Ca Cassandra	Hb HBase	Td Teradata	Cl Cloudera	Mss Microsoft SQL server	Rm RapidMiner	Mat Mathematica	Th Theano	Sp Spotfire	Sav SAS Visual Analytics	Ply Plotly	Ro Rodeo	Be Beaker Notebook
B Bash	Mr Microsoft R Open	P Pig	Mdb Mongo DB	To Toad	Aem Amazon Elastic Mapreduce	Spl Splunk	Cho Chorus	Mah Mahout	Aml Azure Machine Learning	Ql Qlikview	Po PowerPivot	Me Microsoft Excel	Spy Spyder	Ze Apache Zeppelin
Mtl Matlab	Cy Canopy	Im Impala	K Kafka	Ms MySQL	Mar MapR	Sr Solr	Tf Tensorflow	St Stata	D D3	Co Cognos	Gch Google Charts	Pe Pentaho	Dst Data Science Studio	Ju Jupyter
J Java	An Anaconda	Sp Spark	Hi Hive	Ibd IBM DB2	Lu Lucene	El ElasticSearch	Sk Scikit-Learn	Da Dato/Graphlab	My Microstrategy	Aa Adobe Analytics	T Tableau	B Bokeh	Db Databricks notebook	Gh Github

Dw Data.world	Q Quandl	Fte FiveThirtyEight	Sa Socrata	Gp Google Public	Dg Data.gov	K Kaggle
St Statista	Ucl UCI Machine Learning Repository	Wb World Bank	At Academic Torrents	Bf Buzzfeed	Dk DataKind	Dd DrivenData

Re Reddit	So Stack Overflow	Cv Cross Validated	Qu Quora	Av Analytics Vidhya	Dse Data Science Stack Exchange
Mu Meetup	Rdm RDataMining				



Kdn KDnuggets	Ibd insideBIGDATA
Rb R-Bloggers	Pp PlanetPython
Hn HackerNews	Dt DataTau
Dsc Data Science Central	Dsr Data Science Roundup
Dsw Data Science Weekly	Or O'Reilly
Dr Data Elixir	Pw Python Weekly
Rw R Weekly	Pd Partially Derivative
Bds Becoming a Data Scientist	Tm Talking Machines
Ds Data Stories	Dsk Data Skeptic
Ld Linear Digressions	Ns Not So Standard Deviations

• Portanto, estudos de ciência de dados em nosso contexto:



Fonte: [Kirk Bourne](#)

	Devido a sua natureza interdisciplinar, requer intersecção de habilidades (codificação, negócio, matemática e estatística)
	Necessário para trabalhar com massa de dados que precisa ser adquirida, limpa e manipulada
	Permite a escolha de métodos e ferramentas para extrair conhecimento a partir dos dados
	Conhecimento do negócio para demandar questões, estabelecer hipóteses e interpretar os resultados
	Pesquisa tradicional com aplicações estatísticas ao domínio do problema
	Isoladamente não requer conhecimento do negócio, pois pode-se limitar a aplicação de algoritmos, sem propósito individualmente
	Pode levar a análises incorretas, pela falta de métodos matemáticos e estatísticos rigorosos



Exemplos: Concursos públicos, setor privado, parcerias pp etc.

Cientista de dados – aplicações agrícolas