



FUNDAMENTOS E TÉCNICAS EM CIÊNCIAS DE DADOS


PROF. JOSENALDE OLIVEIRA

josenalde.oliveira@ufrn.br

<https://github.com/josenalde/datascience>

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS - UFRN

ELEMENTOS BASE: DADO, INFORMAÇÃO, SISTEMA, CONHECIMENTO



Informação: dado analisado e com algum significado X Conhecimento: informação interpretada, entendida e aplicada

- **Sabemos que os dados podem vir de várias FONTES (do ponto de vista de codificação entender os formatos e como atuar sobre os mesmos (ler, manipular))**



- Exemplo de dado X informação X conhecimento

- Projeto palmaS



Processo (algoritmo)



Conhecimento (negócio): tratamento A, em relação ao tratamento B possui eficácia X, devido à ..., sendo recomendado a aplicação da seguinte forma: ...


Dado: imagem da presença de uma praga chamada cochonilha de escama na palma forrageira após aplicação de determinado tratamento (produto etc.)

Informação: contagem das cochonilhas fêmeas = 114

Fonte das imagens: web e Alyson Miguel

- Exemplo de dado X informação X conhecimento

- Projeto palmaS



Separação por CLASSES

Fonte das imagens: web

Para pensar (exemplos): pulverização autônoma aérea ou térrea



• ASPECTOS DE QUALIDADE DE DADOS

- **Relevantes:** são importantes para o tomador de decisões. Exemplo: se o preço de um tecido vai subir não é relevante para um fabricante de circuitos integrados
- **Simple:** dados sofisticados e/ou detalhados podem não ser necessários. Sobrecarga de informações dificulta tomada de decisão ao invés de auxiliar
- **Apresentadas no momento exato:** saber como foi o tempo semana passada não ajuda a definir que roupa devo usar hoje (temporalidade): marcação de assento de voo, em tempo real?
- **Verificáveis:** deve ser possível checar dados para garantir que estejam corretos, checando por exemplo várias fontes
- **Acessíveis:** fácil acesso para usuários autorizados, com o formato correto (validade: dado de acordo com regra/padrão, tipo, range etc.) e no momento correto

• ASPECTOS DE QUALIDADE DE DADOS

- **Seguras:** evitar acesso não autorizado
- **Compleitude:** falta CEP no endereço?
- **Unicidade:** dois funcionários diferentes com o mesmo CPF?
- **Razoabilidade:** data da receita é anterior à data de preenchimento da compra na farmácia?
- **Integridade:** o mesmo dado tem valores coerentes em bases diferentes?
- **Cobertura:** amplitude geográfica dos dados para realizar o alcance de negócios. Ex. tenho dados do Brasil, mas pretendo entrar no Paraguai
- **Precisão:** moro no Tirol, mas no meu CEP está o de Barro Vermelho. O CEP é válido, o valor existe, mas não é preciso.

ABRANGÊNCIA DA CIÊNCIA DE DADOS

- Objetivo: melhorar o processo de tomada de decisão, por características/informações (não óbvias e úteis) extraídas de grandes conjuntos de dados;

- Percebemos esta realidade em vários segmentos, por exemplo quando:

Recebe-se um anúncio personalizado

Recomendação de filmes, livros e 'amigos'

Filtragem automática (spam list)

Custo de seguros e perfil de clientes

Sequenciamento de semáforos

Chatbots



- Redes sociais
- Poder computacional (custo por MB e por Mbps)
- Métodos eficazes de análise e modelagem, IA
- Acesso à estruturas de coleta, armazenamento e processamento

ABRANGÊNCIA DA CIÊNCIA DE DADOS

MACHINE LEARNING (Aprendizagem de máquina, ML)

Projeto e avaliação de algoritmos para extração de padrões a partir de dados

DATA MINING (Mineração de dados)

Análise de dados estruturados, usualmente com ênfase comercial


Se os dados são textos – mineração de textos, processamento de linguagem natural

A ciência de dados inclui os itens acima, mais o ciclo de dado como um todo, desde a coleta, limpeza e transformação de dados (curadoria) não estruturados (social por exemplo), web tecnologias distribuídas de Big Data e questões gerenciais (governança) e éticas de regulação (LGPD) e uso dos dados

Exemplos:

- 1) Identificar grupos de consumidores com gostos similares (segmentação de mercado): em ciência de dados = CLUSTERING
- 2) Identificar produtos que são comprados juntos (REGRAS DE ASSOCIAÇÃO)
- 3) Detecção de eventos anormais, estranhos, como fraudes etc. = DETECÇÃO DE ANOMALIAS (outliers)
- 4) Classificação (determinar se um dado pertence à determinada CLASSE)
- 5) Predição simples, com **um único atributo**: se um e-mail contiver no conteúdo a frase “ganhe dinheiro fácil” é SPAM. É algo simples, não é necessário ciência de dados...

Exemplo de fontes: [kaggle](#), [dados.gov.br](#), [dados.ufrn.br](#) ([E api.ufrn.br](#))




11

CONCEITOS

“Se um especialista humano pode facilmente criar um padrão em sua própria mente, geralmente não vale a pena o tempo e esforço de usar ciência de dados para descobrir tal padrão” (KELLEHER; TIERNEY, 2018)

Normalmente se aplica a grandes volumes de dados (datasets) cujos padrões sejam difíceis de extrair manualmente. Normalmente até 3 atributos criamos regras facilmente, após isto pode ser tedioso.



CONCEITOS




Por exemplo um Boeing 787 produz 0,5TB de dados durante um voo, a partir de sensores espalhados pela aeronave. Os sensores nos flaps (extensões da asa para sustentação, usadas no pouso por exemplo) emite sinais de vibração (dado). Embora existam dados não eletrônicos (impressos), o foco está em dados eletrônicos, disponíveis em formato digital.

Um dado analógico convertido para digital e persistido torna-se fonte de dados de determinado processo não apenas para monitoramento, mas para ‘descoberta’ de padrões, identificação de relações


Exemplo de fonte de datasets: Kaggle

<https://www.kaggle.com/zynicide/wine-reviews/data?select=winemag-data-130k-v2.csv>



CICLO DE VIDA DO DADO

Podemos entender, portanto, ciência de dados como os processos, modelos e tecnologias que estudam os dados durante todo o seu ciclo de vida, da produção ao descarte




PANORAMA DE CIÊNCIA DE DADOS



Dados, um ativo que vale ouro!

PANORAMA DE CIÊNCIA DE DADOS




Fonte: AMARAL, F. (2018)

E O BIG DATA?




DEFINIÇÕES: DE 3 A 5 V'S...



Virtualização
Computação em nuvem
(IaaS, PaaS, SaaS)
Sistemas Distribuídos

Para os negócios, vantagem competitiva,
Data-driven services, eficiência, antecipação
Minimizar "churn"



Dados são gerados de todas as formas, por todos os lados; Big Data não é uma tecnologia, mas um fenômeno; impacta no conceito de amostragem

A questão é que os eventos sempre existiram e ocorreram, mas os dados não eram REGISTRADOS (datificação)

Um celular hoje com mais capacidade que o melhor PC de 1985
+ de bi de pessoas com telefones
+ de 1,7 bi em redes sociais
+ 3 mi de e-mails por segundo
+ 100 horas de vídeos no YouTube por minuto
+ 500 mi de tweets por dia
+ 100 TB carregados no Facebook etc.